



UNIVERSIDAD AUTÓNOMA METROPOLITANA
UNIDAD IZTAPALAPA

PRACTICA FINAL

Nombre: CARRERA MARTINEZ ISAY JAIRO

Matrícula: 2253801108

Fecha: 23 de julio de 2026

1. PREDICCIÓN DE CONTAMINANTE PM2.5

1.1. INTRODUCCIÓN

En este proyecto analizaremos los cantaminantes atmosfericos especial mente el PM2.5, lo cual nos ayudara a predecir el comportamiento de este contaminante por lo cual al final de este analisis podremos determinar si algun metodo que estaremos trabajando ayudara a poder predecir este contaminante. Para esto utilizaremos la base de datos de contaminantes atmosfericos de la la ciudad de Mexico durante el año 2021-2023, don podemos contar con un total de 876 datos y no solo contamos con los datos de PM2.5 so no de igual manera tenemos CO, NO, NO2, NOX, O3, PM10 Y SO2, por lo cual analizaremos diariamente el comportamiento de unos de estos contaminante en este caso el PM2.5.

Las particulas PM2.5 son contaminante del aire formado por partículas microscópicas de polvo y líquidos tan pequeñas (2.5 micras o menos de diámetro) que son invisibles y pueden penetrar hasta lo más profundo de tus pulmones y torrente sanguíneo por los que estos causan un problemas de salud. Por lo que importante poder predecir estos contaminantes.

1.2. Resultados

La primera Parte de este proyecto consiste en poder analizar de una manera mas detallada el comportamiento del contaminante PM2.5 por lo que al cargar los datos de la base de datos optemos lo siguiente:

		fecha	CO	NO	NO2	NOX	O3	PM10	PM25	SO2
***	0	2021-01-01	0.417782	5.712963	16.977273	23.261574	29.765494	54.327273	28.594855	1.125912
	1	2021-01-02	0.515087	14.289894	26.782609	42.090426	33.647969	48.196481	23.465409	1.725000
	2	2021-01-03	0.446905	12.328571	22.773256	35.714286	28.135823	39.091988	16.423676	1.548983
	3	2021-01-04	0.580398	22.323040	31.306483	54.418052	28.824532	52.486239	23.160000	3.410019
	4	2021-01-05	0.533105	19.386091	29.376218	49.995204	28.941374	55.916667	22.694444	5.251366
...	...	...	...	...	...	...	...	...	...	...
876	2023-05-27	0.256722	3.750583	17.284351	21.629371	41.580645	36.774011	21.170139	2.735683	
877	2023-05-28	0.286826	3.458886	16.349241	20.230769	36.913761	28.580000	18.454861	2.331658	
878	2023-05-29	0.482077	11.448113	24.521154	36.436321	29.697068	30.241486	16.692857	1.071588	
879	2023-05-30	0.441455	13.893519	22.615530	37.224537	36.185971	35.859532	20.888525	1.181818	
880	2023-05-31	0.340404	5.353066	19.372583	25.710359	47.860972	42.203390	24.787097	1.402083	
881 rows x 9 columns										

Figura 1: Visualización de los Datos




Figura 2: Comportamiento de los datos

Como podemos observar durante el periodo de del año 2021 al 2023 donde mas se las partículas PM2.5 las fechas mas afectadas son al inicio del año esto se puede deber a muchas causas como las festividades de año nuevo, donde la muchas familias Mexicanas salen a tronar cohetes, queman sillones para hacer una fogata, o incluso el inmenso traslado que hacen en automoviles y otros medios de transportes para poder pasar estos dias con sus familiares. Posteriormente despues de estas fechas como baja pero al a mitad del año empieza a subir denuevo ya que empiezan otras fechas importantes como el 15 de septiembre, dia de nuestro etc. donde de igual manera festejan de una manera similar al año nuevo.




Figura 3: Entrenamiento de los Metodos

Como se muestra en la gráfica de división temporal, se realizó una partición cronológica de los datos para garantizar una evaluación robusta y evitar el sesgo de información futura. Se destinó el periodo comprendido entre enero de 2021 y septiembre de 2022 para el conjunto de entrenamiento (azul), mientras que el periodo de octubre de 2022 a junio de 2023 se reservó estrictamente como conjunto de prueba (naranja) para evaluar el desempeño final de los modelos bajo condiciones reales de variabilidad del contaminante.

	modelo	MAE	RMSE
3	Random Forest	4.026419	5.531748
1	Regresión lineal	3.894465	5.546210
2	Árbol de decisión	4.223294	5.726960
0	Naive	4.106074	6.254379

Figura 4: Resultados con $\alpha = 0,8$ y epoch = 400.

Como se muestra en la tabla anterior, el modelo Random Forest ofrece un mejor análisis y predicción del contaminante $PM_{2,5}$ durante el periodo 2021-2023, ya que registra el menor valor de RMSE (5,53). Esto demuestra que es el modelo más robusto para mitigar el impacto de los errores grandes y controlar las desviaciones en los picos de contaminación




Figura 5: Comparacion de Modelos




Figura 6: Datos observados vs Datos de Entrenamiento

Como podemos observar Random Forest y Regresion lineal son muy parecido respecto a la prediccion sin embargo al analizar detalladamente Naive se ajusta de mejor manera siguiendo de mejor manera a los datos reales.




Figura 7: Matriz de Correlacion




Figura 8: Importancia de Variables

A partir del análisis de importancia de variables, se identifica que las características con mayor peso predictivo para el comportamiento del contaminante son los registros directos del día (**casos_diario_PM2.5**), representando la variable más influyente con un peso aproximado del 25%. A esto le siguen los indicadores de tendencia acumulada a corto plazo, específicamente el promedio móvil de 3 y 5 días (**promedio_movil_3** y **promedio_movil_5**). Este comportamiento sugiere que la inercia atmosférica inmediata y la acumulación de partículas en los días previos constituyen los factores críticos para que el modelo logre una predicción adecuada del $PM_{2.5}$, por encima de los cambios diarios aislados o los rezagos temporales más distantes como **lag_3**.

	modelo	accuracy
3	Random Forest ajustado	0.615970
0	Naive	0.600760
2	Random Forest inicial	0.593156
1	Árbol	0.528517

Figura 9: Resultados con $\alpha = 0,1$ y epoch = 1500.

1.3. CONCLUSION

Para este proyecto se utilizó como variable principal las partículas $PM_{2.5}$ ya que es uno de los contaminantes más comunes en la CDMX donde es causante de enfermedades respiratorias, donde al tener la investigación Naïve se ajustó mejor ya que se adecua de

mejor manera a los datos reales, para el lado de la clasificacion de igual mente Naives clasifica de mejor manera ya que alcanza un 60

Por lo que al observar las graficas el modelo si se ajusta los dias de contaminacion alto, una vez analizando este contaminante podemos concluir que al usar un solo contaminante no podemos determinar muchos factores como la causa de la fuente del contaminante, que problema podria traer, como interactua los otros contaminantes etc. por lo que es importante contar con mas informacion de otros contaminante.